周宇哲

AI 基础设施 / 后端工程师

北京 · zhou.yuzhe2000@gmail.com · github.com/YuzheZhou2000

个人简介

从事 AI Coding 后端研发，关注大语言模型接入、调用链路与生产稳定性。参与 TRAE 模型网关建设，围绕多模型协议、流量调度和成本优化解决实际问题，也有代码补全与测试生成的工程经验。

工作经历

字节跳动 · TRAE | AI Gateway 服务端 2025.04 - 至今

- 负责大语言模型网关建设，统一不同模型供应商的接入方式，处理流式响应、工具调用与模型能力差异，降低业务接入复杂度。
- 围绕供应波动和调用失败，建设模型路由、队列限流、重试、降级与可观测能力，帮助业务在异常情况下保持服务可用。
- 推进 Prompt Cache 与模型资源调度优化，结合不同模型和流量特征改善资源使用效率，兼顾用户体验与推理成本。
- 参与模型管理平台建设，梳理模型配置、验证与发布流程，并协调研发、测试和产品等团队推进新模型接入。

字节跳动 · MarsCode | 服务端研发实习 2024.01 - 2025.04

- 参与 VS Code 和 JetBrains 场景下的代码补全与单元测试生成链路建设，支持 AI 编程功能从模型调用到编辑器体验的落地。

技术方向

LLM Gateway · 多模型接入 · 模型路由 · 流式协议 · Prompt Cache · 限流与容灾 · 可观测性 · AI Coding

教育经历

哈尔滨工业大学（深圳） | 计算机科学与技术 · 硕士 2022.09 - 2025.04

大连理工大学 | 软件工程 · 本科 2018.09 - 2022.07

研究成果

共同第一作者 · Information Fusion, 2025

Hierarchical Disturbance and Group Inference for Video-based Visible-Infrared Person Re-Identification

doi.org/10.1016/j.inffus.2024.102882